Arquitetura de uma Plataforma Inteligente Baseada em LLM e RAG para Geração e Avaliação de Casos Clínicos no Ensino em Saúde

José Soares da Silva, Emanuel Cândido da Silva Lima, João Pedro Melo Xavier, Anderson Soares Costa

Resumo: Este estudo tem como objetivo propor a arquitetura de uma plataforma inteligente baseada em Large Language Models (LLM) e Retrieval-Augmented Generation (RAG) para a geração e avaliação de casos clínicos no ensino em saúde. A metodologia adotada consiste na definição de uma arquitetura em camadas, composta por interface web para docentes e discentes, API orquestradora, gateway para integração com múltiplas LLMs, banco de dados vetorial para recuperação contextualizada e servidor de arquivos MinIO para armazenamento de documentos clínicos e materiais complementares. Como resultado, a solução proposta permite a geração personalizada de casos clínicos, oferta de dicas progressivas e pré-correção automática das respostas dos alunos, promovendo feedback formativo. Conclui-se que a arquitetura apresenta potencial para otimizar o planejamento didático, reduzir o esforço docente e contribuir para a melhoria do processo de ensino-aprendizagem em cursos da área da saúde.

Palavras-chave: Inteligência Artificial; Ensino em Saúde; Casos Clínicos; Modelos de Linguagem; RAG.

I. INTRODUÇÃO

A utilização de tecnologias baseadas em Inteligência Artificial (IA) no contexto educacional tem ampliado as possibilidades de personalização do ensino, automatização de processos e oferta de feedback em tempo real, especialmente em áreas que demandam forte componente prático, como a saúde [2,3]. No ensino por casos clínicos, a elaboração manual de situações-problema, diagnósticos, exames complementares e critérios de avaliação exige elevado esforço por parte dos docentes, além de demandar constante atualização científica e adequação aos diferentes níveis de formação dos estudantes.

Nos últimos anos, modelos de linguagem de grande porte (*Large Language Models* – LLMs) têm demonstrado elevado potencial na geração de conteúdo textual contextualizado, abrindo novas perspectivas para aplicações em educação e apoio à aprendizagem [1]. Entretanto, ainda se observa uma lacuna na proposição de arquiteturas que integrem, de forma estruturada, recursos de geração inteligente, recuperação contextual por RAG (*Retrieval-Augmented Generation*) e mecanismos de avaliação formativa no contexto do ensino em saúde.

Diante desse cenário, este estudo justifica-se pela necessidade de propor uma solução tecnológica escalável e flexível que auxilie docentes na criação de casos clínicos personalizados e ofereça suporte automatizado ao processo de aprendizagem discente. Assim, o objetivo deste trabalho é propor a arquitetura de uma plataforma inteligente baseada em LLM e RAG para geração e avaliação de casos clínicos no ensino em saúde.

II. DESENVOLVIMENTO E DEMONSTRAÇÃO DOS RESULTADOS

A proposta arquitetural desenvolvida neste trabalho fundamenta-se na aplicação de Inteligência Artificial Generativa, *Large Language Models* (LLMs) e *Retrieval-Augmented Generation* (RAG) como mecanismos de apoio ao ensino por casos clínicos na área da saúde [1, 2]. A arquitetura foi concebida em camadas, visando modularidade, escalabilidade e flexibilidade tecnológica, permitindo futuras evoluções e integração com diferentes provedores de modelos de linguagem, como mostra a Figura I.

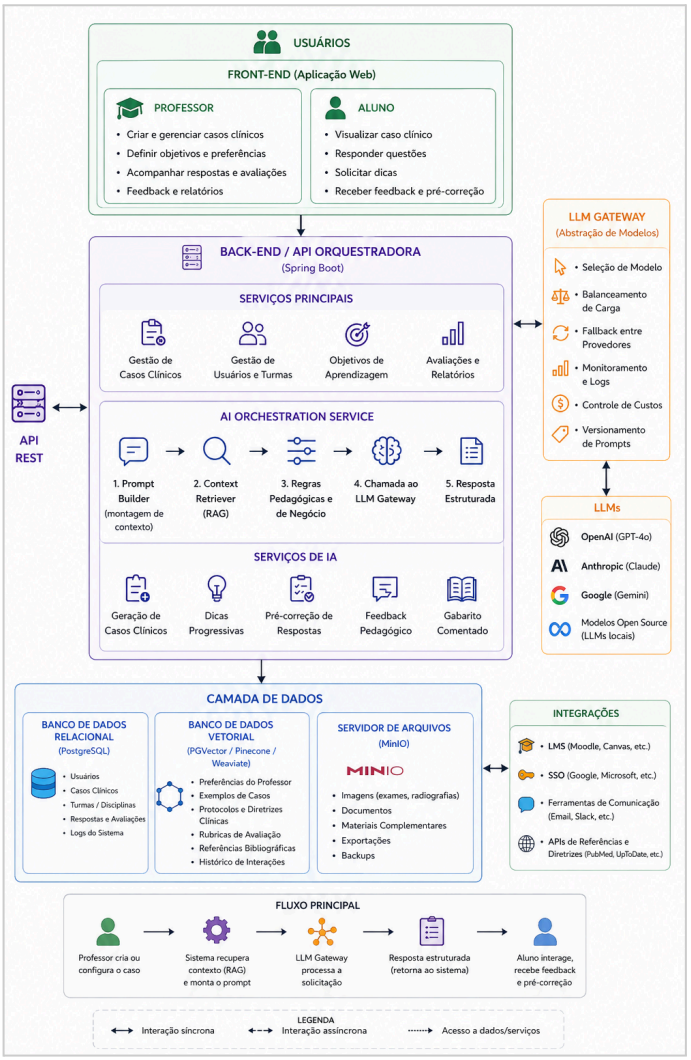
O front-end é uma aplicação web com interfaces distintas para professor e aluno. O professor cria casos clínicos e acompanha o desempenho dos alunos; o aluno visualiza o caso, responde questões e recebe feedback automatizado e dicas progressivas. O acesso é controlado por perfis via RBAC.

O back-end em Spring Boot centraliza as regras de negócio como API orquestradora: valida autenticação, aplica autorização, registra logs e delega ao módulo de IA quando necessário, garantindo rastreabilidade em todas as operações.

O LLM Gateway abstrai os provedores de IA, OpenAI, Anthropic, Google e modelos open source, realizando seleção dinâmica de modelo, balanceamento de carga, fallback automático e versionamento de prompts, evitando dependência de fornecedor único.

Para enriquecer os prompts com contexto pedagógico, o sistema utiliza RAG com banco vetorial, recuperando exemplos de casos, preferências do professor, protocolos clínicos e histórico dos alunos por similaridade semântica[1].

Figura I - Arquitetura Geral



Arquivos não estruturados como imagens de exames e documentos são armazenados no MinIO, solução compatível com S3 que mantém esses conteúdos separados do banco relacional, melhorando performance e garantindo portabilidade entre ambientes .

O fluxo se inicia com o professor configurando o caso; o back-end aciona o pipeline de IA, que monta o prompt, consulta o banco vetorial, aplica regras pedagógicas, chama o LLM Gateway e retorna a resposta estruturada. Na interação do aluno, o mesmo pipeline gera feedback e dicas, registrando todo o histórico para relatórios futuros, conforme a Figura I.

III. CONCLUSÕES

Este trabalho apresentou a arquitetura de uma plataforma para geração e avaliação de casos clínicos com apoio de Inteligência Artificial. A estrutura em camadas desacopladas — front-end, back-end orquestrador, LLM Gateway, módulo RAG e servidor de arquivos — mostrou-se adequada para atender aos requisitos de escalabilidade, flexibilidade e manutenção. O uso do LLM Gateway reduz a dependência de um único provedor, enquanto o RAG amplia a qualidade e a contextualização do conteúdo gerado. Dessa forma, a proposta contribui para o apoio ao desenvolvimento do raciocínio clínico por meio de simulações personalizadas. Como trabalho futuro, prevê-se a implementação de um protótipo e sua validação em cursos da área da saúde.

IV. REFERÊNCIAS

[1]. LEWIS, P.; PEREZ, E.; PIKULIN, A.; PETRONI, F.; KARPATNE, A.; OGUZ, B.; ILHARCO, G.; MEHDIZADEH, M.; BOHNET, B.; YIH, W. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Advances in Neural Information Processing Systems, 2020.

[2]. NEVES, A. V. S. C.; MACÊDO, W. C. M.; FIALHO, L. M. F. Inteligência Artificial na Educação Médica: evidências dos estudos latino-americanos. Revista Eletrônica Científica Ensino Interdisciplinar, v. 11, n. 35, 2025.

[3]. LOBO, P.; BRASIL, L. S. B. Uso da inteligência artificial na medicina e educação médica. Revista de Saúde Digital e Tecnologias Educacionais, v. 9, n. 2, 2024.



João Pedro Melo Xavier, Estudante de engenharia de software, UNIFSA, https://lattes.cnpq.br/9564783673704128, https://orcid.org/0009-0005-6917-7845, joao.pmx7@gmail.com,



Anderson Soares Costa, Orientador, Mestre, UNIFSA, http://lattes.cnpq.br/3643002419609942, andersoncosta@unifsa.com.br, https://orcid.org/0000-0002-9886-3909, andersoncosta@unifsa.com.br,



Emanuel Cândido da Silva Lima, Estudante de engenharia de Software, UNIFSA, https://lattes.cnpq.br/3606330390155769, https://orcid.org/0009-0003-1773-7519, emanoelcandidolima@gmail.com,



José Soares da Silva, Estudante de engenharia de software, UNIFSA, https://lattes.cnpq.br/4396984698520472, https://orcid.org/0009-0005-7557-8573, josesoaresdasilva033@gmail.com